

Ocena ryzyka kredytowego

Porównanie systemów opartych na logice rozmytej
(Fuzzy Logic) oraz uczeniu maszynowym

Metody Systemowe i Decyzyjne

Zadanie semestralne do realizacji na laboratorium

Politechnika Wrocławska

Jakub Iwanicki 284328

Adrian Loba 284273

31.05.2026

Spis treści

1. STRESZCZENIE.....	2
2. WSTĘP I SFORMUŁOWANIE PROBLEMU	2
2.1 Kontekst biznesowy	2
2.2 Cel badań	2
2.3 Hipotezy badawcze	3
3. METODOLOGIA BADAWCZA I PRZYGOTOWANIE DANYCH	3
3.1 Zbiór danych	3
3.2 Preprocessing danych.....	3
3.3 Różnicowanie wymiarowości	4
3.4 Metryki ewaluacyjne.....	4
4. OMÓWIENIE ALGORYTMÓW.....	4
4.1 Modele uczenia maszynowego.....	4
4.2 Systemy oparte na logice rozmytej	5
5. WYNIKI EKSPERYMENTÓW.....	6
5.1 Zestawienie wyników	6
5.2 Wizualizacja wyników.....	7
5.3 Analiza macierzy pomyłek	9
6. ANALIZA WYNIKÓW I WNIOSKI.....	11
6.1 Przewaga podejścia data-driven.....	11
6.2 Efektywność obliczeniowa	11
6.3 Przekleństwo wymiarowości w systemach rozmytych	11
6.4 Brak wpływu kształtu funkcji przynależności.....	12
6.5 Paradoks trzeciego atrybutu	12
6.6 Wnioski końcowe	12
6.7 Explainable AI (XAI)	13
6.8 Rekomendacje praktyczne	14
7. WNIOSKI INDYWIDUALNE Z REALIZACJI PROJEKTU.....	15

1. Streszczenie

Niniejszy raport przedstawia wyniki eksperymentalnego porównania dwóch paradygmatów budowy systemów decyzyjnych w kontekście problemu oceny ryzyka kredytowego: systemów opartych na regułach z wykorzystaniem logiki rozmytej (weak AI / rule-based AI) oraz modeli uczenia maszynowego (data-driven AI). Badania przeprowadzono na zbiorze German Credit Data, stosując standaryzację danych oraz technikę oversamplingu SMOTE w celu zbalansowania klas. Wyniki jednoznacznie wskazują na przewagę podejścia opartego na uczeniu maszynowym zarówno pod względem dokładności predykcji (Accuracy do 75%, F1-Score do 0.749), jak i efektywności obliczeniowej. Systemy rozmyte, mimo teoretycznej interpretowalności, wykazały znacznie niższą skuteczność (Accuracy 59.5–71.5%) oraz problemy ze skalowalnością związane z wykładniczym wzrostem liczby reguł przy zwiększaniu wymiarowości problemu. Dodatkowo, analiza macierzy pomyłek uwydatniła zbalansowaną zdolność dyskryminacyjną modeli ML w opozycji do tendencji systemów rozmytych do błędnego akceptowania ryzykownych klientów. Całość uzupełniono badaniem w oparciu o metodologię SHAP (Explainable AI), co pozwoliło zademonstrować, że modele data-driven mogą osiągnąć wymagany biznesowo poziom interpretowalności, obalając mit o ich całkowitej nieprzejrzystości.

2. Wstęp i sformułowanie problemu

2.1 Kontekst biznesowy

Ocena ryzyka kredytowego stanowi jeden z fundamentalnych problemów decyzyjnych w sektorze finansowym. Poprawna klasyfikacja klientów na tych, którzy spłacą zobowiązanie (klasa pozytywna) oraz tych, którzy mogą nie wywiązać się z umowy (klasa negatywna), ma bezpośredni wpływ na rentowność instytucji finansowych oraz stabilność systemu bankowego.

2.2 Cel badań

Celem niniejszego projektu było przeprowadzenie porównawczej analizy dwóch fundamentalnie różnych podejść do budowy systemów decyzyjnych:

1. **Systemy oparte na regułach (Rule-based AI)** - wykorzystujące logikę rozmytą (Fuzzy Logic) do modelowania niepewności i nieostrości pojęć lingwistycznych, charakterystyczne dla paradygmatu weak AI.
2. **Systemy uczenia maszynowego (Machine Learning)** - podejście data-driven, gdzie model autonomicznie uczy się wzorców decyzyjnych na podstawie danych historycznych.

2.3 Hipotezy badawcze

Sformułowano następujące hipotezy:

- **H1:** Modele ML osiągną wyższą dokładność predykcji dzięki zdolności do analizy wielowymiarowych zależności w danych.
 - **H2:** Systemy rozmyte wykażą problemy ze skalowalnością przy zwiększaniu liczby atrybutów wejściowych.
 - **H3:** Kształt funkcji przynależności w systemach rozmytych będzie miał ograniczony wpływ na dokładność przy braku wiedzy eksperckiej.
-

3. Metodologia badawcza i przygotowanie danych

3.1 Zbiór danych

W eksperymentach wykorzystano zbiór **German Credit Data** - standardowy benchmark w dziedzinie credit scoringu, zawierający 1000 obserwacji opisanych 20 atrybutami charakteryzującymi historię kredytową, sytuację finansową oraz dane demograficzne klientów.

3.2 Preprocessing danych

Proces przygotowania danych obejmował następujące etapy:

1. **Standaryzacja** - zastosowano transformację StandardScaler w celu normalizacji rozkładów zmiennych numerycznych, co jest wymagane przez niektóre algorytmy (np. regresję logistyczną).
2. **Obsługa niebalansowania klas** - zbiór German Credit Data charakteryzuje się nierównomiernym rozkładem klas (przewaga kredytów spłaconych nad niespłaconymi w proporcji ok. 70:30). W celu przeciwdziałania tendencji modeli do faworyzowania klasy większościowej zastosowano algorytm **SMOTE (Synthetic Minority Over-sampling Technique)** na zbiorze treningowym. SMOTE generuje syntetyczne przykłady klasy mniejszościowej poprzez interpolację między istniejącymi obserwacjami w przestrzeni cech.
3. **Podział danych** - zbiór podzielono na część treningową (80%) i testową (20%) z zachowaniem stratyfikacji.

3.3 Różnicowanie wymiarowości

Ze względu na ograniczenia biblioteki skfuzzy dotyczące efektywnego przetwarzania wielowymiarowych przestrzeni reguł:

- **Modele ML** - wykorzystywały pełny zestaw 20 atrybutów.
- **Systemy rozmyte** - operowały na zredukowanej przestrzeni 2 atrybutów (wiek, kwota kredytu) lub 3 atrybutów (wiek, kwota kredytu, czas trwania).

3.4 Metryki ewaluacyjne

Do oceny jakości modeli wykorzystano:

- **Accuracy** - odsetek poprawnie sklasyfikowanych obserwacji.
- **F1-Score** - średnia harmoniczna precyzji i czułości, istotna przy niezbalansowanych zbiorach.
- **Czas predykcji** - czas wykonania klasyfikacji na zbiorze testowym (w sekundach).

4. Omówienie algorytmów

4.1 Modele uczenia maszynowego

4.1.1 *Random Forest*

Zespołowy algorytm bazujący na agregacji wielu drzew decyzyjnych trenowanych na losowych podzbiorach danych i cech. Hiperparametry (liczba drzew, maksymalna głębokość, minimalna liczba próbek w liściu) zostały zoptymalizowane przy użyciu **GridSearchCV** z 5-krotną walidacją krzyżową.

4.1.2 *Logistic Regression*

Klasyczny model liniowy szeroko stosowany w sektorze bankowym ze względu na interpretowalność współczynników. Model szacuje prawdopodobieństwo przynależności do klasy pozytywnej przy użyciu funkcji sigmoidalnej.

4.1.3 *Decision Tree*

Pojedyncze drzewo decyzyjne z domyślnymi parametrami. Model charakteryzuje się wysoką interpretowalnością, lecz tendencją do przeuczenia.

4.1.4 *Linear Regression (zaadaptowana)*

Model regresji liniowej przystosowany do zadania klasyfikacji poprzez zastosowanie progu odcięcia na poziomie 0.5 dla predykowanych wartości ciągłych.

4.2 Systemy oparte na logice rozmytej

4.2.1 Architektura systemu

System rozmyty zaimplementowano w bibliotece scikit-fuzzy zgodnie z architekturą Mamdaniego, obejmującą:

- **Fuzyfikację** - mapowanie wartości numerycznych na stopnie przynależności do zbiorów rozmytych.
- **Bazę reguł** - zbiór reguł IF-THEN definiujących logikę decyzyjną.
- **Mechanizm wnioskowania** - agregację aktywowanych reguł.
- **Defuzyfikację** - konwersję wyniku rozmytego na wartość ostrą (metodą centroidu).

4.2.2 Generator bazy reguł

Ze względu na brak dostępu do eksperta dziedzinowego z sektora bankowego, bazę reguł wygenerowano **heurystycznie** poprzez uśrednianie indeksów lingwistycznych zmiennych wejściowych. Przykładowo, dla zmiennych o wartościach lingwistycznych {niski=0, średni=1, wysoki=2}, reguła łącząca "wiek=niski" i "kwota=wysoka" generowała ryzyko o indeksie $(0+2)/2 = 1$, czyli "średnie". Podejście to stanowi znaczące uproszczenie w stosunku do rzeczywistej wiedzy eksperckiej.

4.2.3 Badane konfiguracje

Przeprowadzono eksperymenty badające wpływ:

- **Liczby funkcji przynależności**: 3, 5 lub 7 przedziałów lingwistycznych.
 - **Kształtu funkcji przynależności**: trójkątne (trimf), gaussowskie (gaussmf), trapezowe (trapmf).
 - **Wymiarowości**: 2 atrybuty vs 3 atrybuty.
-

5. Wyniki eksperymentów

5.1 Zestawienie wyników


Tabela 1 przedstawia kompletne zestawienie wyników dla wszystkich testowanych konfiguracji.

Tabela 1. Porównanie dokładności i czasu wykonania testowanych modeli


Metodologia	Model / Konfiguracja	Czas [s]	Accuracy	F1-Score
Machine Learning	Random Forest (tuned)	0.0033	0.750	0.749
Machine Learning	Logistic Regression	0.0019	0.720	0.731
Machine Learning	Decision Tree	0.0001	0.715	0.718
Machine Learning	Linear Regression	0.0020	0.715	0.726
Fuzzy Logic	2 atrybuty, 3× trimf (Baza)	0.3412	0.620	0.633
Fuzzy Logic	2 atrybuty, 3× gaussmf	0.2816	0.620	0.633
Fuzzy Logic	2 atrybuty, 3× trapmf	0.2504	0.620	0.633
Fuzzy Logic	2 atrybuty, 5× trimf	0.9107	0.595	0.612
Fuzzy Logic	2 atrybuty, 7× trimf	2.2599	0.620	0.633
Fuzzy Logic	3 atrybuty, 3× trimf	1.0798	0.715	0.664

5.2 Wizualizacja wyników

Rysunek 1 przedstawia graficzne porównanie dokładności, natomiast rysunek 2 odzwierciedla czas wykonania wszystkich testowanych konfiguracji.




Rysunek 1. Porównanie dokładności (Accuracy) dla modeli uczenia maszynowego (kolor czerwony) i systemów rozmytych (kolor niebieski).




Rysunek 2. Porównanie czasu predykcji dla modeli uczenia maszynowego (kolor czerwony) i systemów rozmytych (kolor niebieski).

5.3 Analiza macierzy pomyłek

W celu głębszego zrozumienia charakterystyki predykcji najlepszych modeli z obu metodologii, przeprowadzono analizę macierzy pomyłek dla Random Forest (tuned) oraz systemu rozmytego z 3 atrybutami i 3 funkcjami trójkątnymi.



Rysunek 3. Macierz pomyłek dla najlepszego modelu ML (Random Forest)



Rysunek 4. Macierz pomyłek dla najlepszej konfiguracji systemu rozmytego (3 atrybuty, 3x trimf)

Interpretacja wyników

Analiza macierzy pomyłek ujawnia fundamentalne różnice w strategiach klasyfikacyjnych obu podejść:

1. Random Forest wykazuje zbalansowane podejście do obu klas, osiągając wysoką precyzję (81.7%) przy jednoczesnym zachowaniu dobrej czułości (82.9%). Model popełnia zbliżoną liczbę błędów typu False Positive (26) i False Negative (24), co świadczy o równomiernej dyskryminacji obu klas.
2. System rozmyty charakteryzuje się wyraźnym przesunięciem w kierunku klasyfikowania obserwacji jako "dobry kredyt" (klasa pozytywna). Wysoki Recall (93.6%) oznacza, że model prawidłowo identyfikuje niemal wszystkich klientów spłacających kredyt, jednak kosztem bardzo niskiej specyficzności - aż 48 klientów niespłacających zostało błędnie sklasyfikowanych jako wiarygodnych (False Positive).
3. Implikacje biznesowe: Z perspektywy instytucji finansowej, system rozmyty generowałby znacznie wyższe straty kredytowe, ponieważ błędnie akceptowałby 4-krotnie więcej niespłacalnych klientów (48 vs 26). Random Forest oferuje lepszy kompromis między akceptowaniem dobrych klientów a odrzucaniem ryzykownych.

6. Analiza wyników i wnioski

6.1 Przewaga podejścia data-driven

Wyniki eksperymentów jednoznacznie potwierdzają hipotezę H1 - modele uczenia maszynowego osiągnęły znacząco wyższą skuteczność predykcji w porównaniu z systemami opartymi na logice rozmytej. Najlepszy model ML (Random Forest po tuningu hiperparametrów) uzyskał Accuracy na poziomie 75.0% i F1-Score równy 0.749, podczas gdy najlepsza konfiguracja systemu rozmytego (3 atrybuty, 3× trimf) osiągnęła jedynie 71.5% Accuracy przy F1-Score 0.664.

Różnica ta wynika z fundamentalnych różnic w mechanizmie działania obu podejść:

- **Modele ML** autonomicznie wykrywają złożone, nieliniowe zależności między 20 atrybutami a zmienną celu, ucząc się na zbalansowanych danych (dzięki SMOTE).
- **Systemy rozmyte** bazowały na uproszczonej heurystyce matematycznej operującej jedynie na 2–3 cechach, co drastycznie ograniczało ich zdolność do odwzorowania rzeczywistej złożoności problemu.

6.2 Efektywność obliczeniowa

Analiza czasów wykonania ujawnia dramatyczną różnicę w efektywności obliczeniowej na korzyść modeli ML. Najszybszy model ML (Decision Tree) wykonywał predykcję w czasie 0.0001 s, podczas gdy najprostsza konfiguracja systemu rozmytego wymagała 0.25 s - różnica rzędu **trzech rzędów wielkości**. Random Forest, mimo złożoności zespołowej, osiągał czas 0.0033 s, co czyni go ponad 100-krotnie szybszym od bazowej konfiguracji fuzzy.

6.3 Przekleństwo wymiarowości w systemach rozmytych

Wyniki w pełni potwierdzają hipotezę H2 dotyczącą problemów skalowalności systemów rozmytych. Zaobserwowano:

1. **Wzrost liczby funkcji przynależności:** Zwiększenie z 3 do 7 przedziałów lingwistycznych (przy 2 atrybutach) spowodowało wzrost czasu wykonania z 0.34 s do 2.26 s (wzrost 6.6-krotny) **bez poprawy dokładności** (Accuracy pozostało na poziomie 62.0%).
2. **Dodanie trzeciego atrybutu:** Rozszerzenie z 2 do 3 wymiarów (przy 3 funkcjach przynależności) wydłużyło czas z 0.34 s do 1.08 s (wzrost 3.2-krotny).

Zjawisko to wynika z **wykładniczego wzrostu liczby reguł** w bazie wiedzy. Dla n atrybutów i k funkcji przynależności każdy, system musi przetworzyć k^n reguł. Przykładowo:

- 2 atrybuty × 7 funkcji = 49 reguł
- 3 atrybuty × 7 funkcji = 343 reguły

W implementacji skfuzzy każda obserwacja wymaga pełnego przetworzenia wszystkich reguł, co czyni podejście niepraktycznym dla problemów o większej wymiarowości.

6.4 Brak wpływu kształtu funkcji przynależności

Hipoteza H3 została potwierdzona - zmiana kształtu funkcji przynależności (trimf, gaussmf, trapmf) przy identycznej liczbie przedziałów nie wpłynęła na dokładność klasyfikacji (wszystkie konfiguracje 2-atrybutowe z 3 funkcjami osiągnęły identyczne Accuracy = 62.0% i F1 = 0.633). Obserwacja ta sugeruje, że przy braku wiedzy eksperckiej do kalibracji parametrów funkcji, ich kształt ma marginalne znaczenie - głównym ograniczeniem pozostaje jakość bazy reguł.

6.5 Paradoks trzeciego atrybutu

Interesującym wynikiem jest fakt, że dodanie trzeciego atrybutu (czas trwania kredytu) do systemu rozmytego podniosło Accuracy z 62.0% do 71.5%, zbliżając wynik do modeli ML. Jednakże F1-Score wzrósł jedynie do 0.664 (vs 0.718–0.749 dla ML), co sugeruje, że poprawa Accuracy wynikała głównie z lepszej klasyfikacji klasy większościowej, a nie z rzeczywistej poprawy zdolności dyskryminacyjnej modelu.


6.6 Wnioski końcowe

1. **Podejście data-driven (ML) zdecydowanie przewyższa rule-based (Fuzzy Logic)** w kontekście oceny ryzyka kredytowego pod względem zarówno dokładności, jak i efektywności obliczeniowej.
2. **Random Forest z optymalizacją hiperparametrów** okazał się najskuteczniejszym modelem, osiągając najwyższe wartości obu metryk przy akceptowalnym czasie wykonania.
3. **Systemy rozmyte wymagają wiedzy eksperckiej** - heurystyczne generowanie bazy reguł nie jest w stanie zastąpić rzeczywistej wiedzy dziedzinowej bankowego analityka ryzyka. Bez eksperta biznesowego systemy te pozostają jedynie akademickim ćwiczeniem.
4. **Skalowalność stanowi fundamentalne ograniczenie** systemów rozmytych w bibliotece skfuzzy. Wykładniczy wzrost złożoności obliczeniowej przy zwiększaniu wymiarowości czyni je niepraktycznymi dla problemów o więcej niż kilku atrybutach.
5. **Technika SMOTE** okazała się skuteczna w poprawie zdolności modeli ML do klasyfikacji klasy mniejszościowej, co potwierdza wartości F1-Score zbliżone do Accuracy.

6.7 Explainable AI (XAI)

Fundamentalnym argumentem przemawiającym często za systemami opartymi na logice rozmytej (rule-based AI) jest ich interpretowalność, oparta na zrozumiałych dla eksperta regułach lingwistycznych. Modele uczenia maszynowego, takie jak wykorzystany w badaniu Random Forest, uchodzą z reguły za "czarne skrzynki", co bywa barierą w instytucjach finansowych, gdzie transparentność decyzji kredytowych jest kluczowa.

Aby zweryfikować tę tezę, przeprowadzono analizę najlepszego modelu uczenia maszynowego (Random Forest) wykorzystując metodologię SHAP (SHapley Additive exPlanations), wywodzącą się z teorii gier kooperacyjnych. Wygenerowany wykres podsumowujący (SHAP summary plot) pozwala precyzyjnie przeanalizować logikę decyzyjną modelu na poziomie globalnym, uwzględniając całą, 20-wymiarową przestrzeń atrybutów.



Rysunek 5. Podsumowujący wykres wartości Shapley'a (SHAP summary plot) dla najlepszego modelu Random Forest, ilustrujący globalny wpływ oraz istotność 20 atrybutów na ocenę ryzyka kredytowego.

Analiza wygenerowanego profilu SHAP dostarcza kluczowych wniosków dotyczących modelu:

- **Hierarchia ważności cech:** Oś pionowa uporządkowana jest według wagi predykcyjnej cech (od najważniejszych na górze). Model wskazuje, że do trzech najbardziej krytycznych zmiennych decydujących o ocenie ryzyka należą: status obecnego konta bankowego (`checking_status`), status oszczędności (`savings_status`) oraz czas trwania kredytu (`duration`).

Analiza kierunku wpływu (korelacje nieliniowe):

- **Zmienne finansowe (status konta i oszczędności):** Widoczne jest wyraźne rozwarstwienie – wysokie wartości tych cech (kolor czerwony) silnie wpływają na pozytywną ocenę kredytową (kropki po prawej stronie od osi pionowej), podczas gdy niskie wartości (kolor niebieski) zwiększają ryzyko (przesunięcie w lewo).
- **Zmienna czasowa (duration):** Zależność jest odwrotna – długi czas kredytowania (kolor czerwony) jest przez model postrzegany jako czynnik zwiększający ryzyko (skupisko punktów z lewej strony).
- **Głębsze zależności (np. wiek i cel):** Zmienne znajdujące się niżej w hierarchii, takie jak wiek (`age`) czy cel kredytu (`purpose`), wykazują mniejszą wariancję na osi X, co oznacza, że model przypisuje im rolę jedynie czynników wspomagających, a nie kluczowych dyskryminatorów ryzyka.

Wnioski końcowe

Zastosowanie technik XAI obala mit o całkowitej nieprzejrystości modeli *data-driven*. Odpowiednio zaimplementowane metody (takie jak SHAP) pozwalają nie tylko zrozumieć wagę poszczególnych atrybutów, ale i precyzyjnie śledzić logikę przydzielania oceny ryzyka dla każdego klienta. Udowadnia to, że modelowanie oparte na uczeniu maszynowym może z powodzeniem zastąpić systemy rozmyte (Fuzzy Logic), oferując jednocześnie bezkonkurencyjną dokładność, efektywność obliczeniową oraz wymagany przez biznes poziom interpretowalności.

6.8 Rekomendacje praktyczne

Dla zastosowań produkcyjnych w sektorze finansowym rekomenduje się stosowanie modeli uczenia maszynowego (preferowany Random Forest lub Gradient Boosting). Systemy oparte na logice rozmytej mogą znaleźć zastosowanie jedynie w scenariuszach wymagających pełnej interpretowalności decyzji i przy dostępie do wiedzy eksperta dziedzinowego zdolnego do zdefiniowania precyzyjnej bazy reguł.

7. Wnioski indywidualne z realizacji projektu

Z perspektywy realizacji projektu, kluczowym etapem z punktu widzenia inżynierskiego była implementacja i analiza złożoności obliczeniowej obu systemów. Praktyczne testy wykazały radykalny spadek wydajności algorytmów z rodziny Fuzzy Logic przy zwiększaniu liczby wymiarów, co potwierdziło występowanie problemu przekleństwa wymiarowości i trudności w ich skalowaniu. Równocześnie zastosowanie biblioteki SHAP do modelu Random Forest pozwoliło w praktyce zweryfikować możliwość ilościowego wyjaśnienia decyzji modelu na poziomie pojedynczych atrybutów. Wyniki tego etapu potwierdzają, że modele oparte na uczeniu maszynowym mogą być z powodzeniem audytowane pod kątem interpretowalności w ściślejszych zastosowaniach finansowych. Tym samym wyniki projektu jednoznacznie wskazują, że w problemach o ustrukturyzowanych danych historycznych podejście data-driven stanowi metodologicznie dojrzałą alternatywę dla systemów regułowych, zarówno pod względem skuteczności, skalowalności, jak i audytowalności.
